

基于多尺度 1D-CNN 和注意力机制的汇率多步预测研究

王 刚^{1,2}, 陈 红¹, 马敬玲¹, 王 珏³

(1. 合肥工业大学 管理学院, 合肥 230009; 2. 过程优化与智能决策教育部重点实验室, 合肥 230009; 3. 中国科学院
数学与系统科学研究院, 北京 100190)

摘 要 深度学习在处理时间序列数据上具有优势, 在汇率时间序列的应用研究中, 目前深度学习主要关注于单步预测, 即利用以前时点的数据预测下一个时点的汇率数据. 然而, 在实际应用中, 这种单步预测方式往往无法为决策者提供足够的决策信息; 同时, 由于汇率时间序列呈现出非平稳、复杂度高等特点, 直接利用传统深度学习方法进行预测无法充分挖掘汇率序列的特征及规律. 为此, 本研究提出一种基于多尺度一维卷积神经网络 (1D-CNN) 和注意力机制的汇率多步预测方法, 该方法在自适应的融合多尺度特征的同时, 差异化的融合汇率不同时刻的时间序列特征, 实现汇率的多步预测. 通过实验发现, 所提方法相较于基准方法, 如差分整合移动平均自回归模型、支持向量回归、随机游走、极限梯度提升算法、长短期记忆网络等具有更高的预测精度, 表明该方法能够为外汇市场投资者提供决策支持.

关键词 汇率多步预测; 深度学习; 多尺度 1D-CNN; 注意力机制

Multi-step forecasting of exchange rate based on multi-scale 1D-CNN and attention mechanisms

WANG Gang^{1,2}, CHEN Hong¹, MA Jingling¹, WANG Jue³

(1. School of Management, Hefei University of Technology, Hefei 230009, China; 2. The Ministry of Education Key Laboratory of Process Optimization and Intelligent Decision, Hefei 230009, China; 3. Academy of Mathematics and Systems Science, Chinese Academy of Sciences, Beijing 100190, China)

Abstract Deep learning has advantages in processing time series data. Currently, in the applied research of exchange rate time series, deep learning mainly focuses on single-step prediction, which only uses data from previous time points to predict exchange rate data for the next time point. However, this one-step prediction method often fails to provide sufficient decision-making information for decision makers. At the same time, due to the characteristics of non-stationary and high complexity of exchange rate time series, using traditional deep learning methods for forecasting cannot fully explore the characteristics of exchange rate series. Therefore, this study proposes a multi-step prediction method of exchange rate based on multi-scale one-dimensional convolution neural network (1D-CNN) and attention mechanisms, which adaptively integrates

收稿日期: 2023-04-10

作者简介: 通信作者: 王刚 (1980–), 男, 汉, 江苏赣榆人, 博士, 教授, 研究方向: 信息管理与信息系统, E-mail: wgedison@hfut.edu.cn; 陈红 (1998–), 女, 汉, 安徽省合肥人, 硕士研究生, 研究方向: 商务智能, E-mail: 2021170891@mail.hfut.edu.cn; 马敬玲 (1996–), 女, 汉, 安徽亳州人, 博士研究生, 研究方向: 智能风控与金融序列预测, E-mail: majingling1626@163.com; 王珏 (1979–), 女, 汉, 博士, 研究员, 研究方向: 智能计算和经济预测, E-mail: wjue@amss.ac.cn.

基金项目: 国家自然科学基金 (72071062, 72371096); 安徽省杰出青年基金 (2208085J12)

Foundation item: National Natural Science Foundation of China (72071062, 72371096); Anhui Province Outstanding Youth Fund (2208085J12)

中文引用格式: 王刚, 陈红, 马敬玲, 等. 基于多尺度 1D-CNN 和注意力机制的汇率多步预测研究 [J]. 系统工程理论与实践, 2024, 44(6): 1934–1949.

英文引用格式: Wang G, Chen H, Ma J L, et al. Multi-step forecasting of exchange rate based on multi-scale 1D-CNN and attention mechanisms[J]. Systems Engineering — Theory & Practice, 2024, 44(6): 1934–1949.

multi-scale features and differentiated time series features of exchange rate at different moments to achieve multi-step prediction of exchange rate. Experiments show that the proposed method has higher prediction accuracy than the benchmark methods such as autoregressive integrated moving average model (ARIMA), support vector regression (SVR), Random Walk (RW), eXtreme gradient boosting (XGBoost), long short term memory (LSTM), etc., which indicates that the proposed method can provide decision support for foreign exchange market investors.

Keywords multi-step forecasting of exchange rate; deep learning; multi-scale 1D-CNN; attention mechanisms

1 引言

随着经济全球化的不断发展, 汇率作为连接国家之间交易的纽带, 影响着国家经济的稳定性. 由于汇率的波动会对国际贸易和金融投资产生较大的影响, 科学分析汇率变动、准确预测汇率值, 具有重要的理论研究意义和实际应用价值. 汇率预测一方面有助于私人投资者及时调整投资策略、分散风险, 从而获得更多利润, 另一方面也有助于跨国企业在国际交易中做出更好的风险管理决策, 降低汇率波动带来的风险. 然而, 由于外汇市场是一个典型的复杂动态系统, 汇率数据具有非线性、非平稳性、高波动性和不规则性等特征^[1], 使得准确预测汇率波动变得极为困难. 因此, 如何构建一种有效的汇率预测方法已成为金融业和学术界广泛关注的问题.

作为金融领域的重要课题之一, 大量的国内外研究者都致力于开发高精度的汇率预测方法. 早期研究者利用统计学相关理论对汇率的波动和趋势进行了大量深入的研究, 包括自回归滑动平均模型 (autoregressive moving average model, ARMA)、差分整合移动平均自回归模型 (autoregressive integrated moving average model, ARIMA)、广义自回归条件异方差模型 (generalized autoregressive conditional heteroscedasticity, GARCH) 和随机游走 (random walk, RW) 等. 尽管已有研究证明统计方法在汇率预测中的有效性, 但此类方法的预测精度仍有待提高. 因为这些统计方法往往基于数据是线性和平稳的假设, 然而汇率等金融时间序列并不符合这样的假设. 与上述统计方法相比, 机器学习方法对于数据的限制和假设较少, 对具有非线性特征的数据能够实现有效建模. 人工神经网络 (artificial neural network, ANN)、支持向量回归 (support vector regression, SVR)、逻辑回归 (logistic regression, LR) 等都是常见的传统机器学习方法. ANN 在处理非线性和非平稳性数据集上具有一定优势. 然而, ANN 可能会陷入局部极小值, 从而导致汇率预测结果不稳定^[2]. 相较于 ANN, SVR 因其结构化风险最小的目标而具备优秀的泛化能力^[3]. 以上单个模型在一定程度上提高了汇率预测精度, 但是它们可能存在预测效果不稳定、误差过大等问题^[4]. 为了解决该问题, Dasarathy 提出了集成学习方法, 如随机森林 (Random Forest, RF)、Adaboost 等. 随机森林对于汇率预测等不平稳数据有着天然的优势, 通常表现良好^[5]. Adaboost 具有很强的泛化能力, 但是训练的时间过长, 尤其是对于数据量较大的样本耗费的时间更长^[6].

与传统方法相比, 深度学习方法对于汇率预测更具有优势, 因为它能够更好地学习输入变量之间的复杂非线性关系, 从而取得较好的预测结果. 以循环神经网络 (recurrent neural network, RNN) 和卷积神经网络 (convolutional neural networks, CNN) 为代表的深度学习方法在汇率预测领域开展了很多深入研究. RNN 是具有短期记忆能力的神经网络, 常被用于时间序列相关问题. 然而, RNN 可能存在梯度消失, 无法解决长期依赖的问题. LSTM 由于其三个独特的门结构很好地解决了梯度消失的问题, 并增强了长期记忆的能力. GRU 在 LSTM 的基础上减少并合并了 LSTM 的门结构, 不仅保证了精度还增加了网络训练的速度. CNN 通过卷积和池化操作从局部感受野中提取局部特征和深层特征, 具有较强的学习能力, 但传统的 CNN 只使用固定大小的卷积核来提取特征, 无法提取综合特征^[7]. 尽管上述深度学习方法广泛应用于汇率预测, 但仍有一些重要问题需要考虑. 一方面, 大多数深度学习汇率预测研究关注于单步预测, 所获得的结果无法为决策者提供足够的决策信息; 另一方面, 由于汇率数据具有非平稳的特征, 直接利用传统深度学习方法进行预测无法充分挖掘汇率序列的特征及规律, 因此, 汇率预测精度还有待提升.

为了解决上述问题, 本研究提出了一种基于多尺度 1D-CNN 网络和双重注意力机制 (dual attention-

based multi-scale one-dimensional convolutional neural networks, DAMS-1DCNN) 的深度学习方 法, 实现对未来多个时间步汇率值的预测. 该方法采用编码器-解码器作为基本框架用于多步预测, 首先, 利用多尺度 1D-CNN 对时间序列进行不同精细度的特征提取以降低汇率数据非平稳特征带来的不利影响, 并使用尺度注意力机制融合多尺度目标特征, 通过对不同尺度特征的权重计算, 以提高特征有效性; 然后, 利用时间注意力机制赋予不同时间步相应权重以更充分的挖掘汇率序列的特征及规律, 进一步提高模型预测精度; 最后, 引入双向循环神经网络 (bidirectional gated recurrent unit, Bi-GRU) 进一步挖掘时间序列过去和未来的动态特征, 对汇率进行多步预测. 为了验证本研究所提方法的有效性, 在三对汇率对的数据集上进行实验. 实验结果表明, 基于多尺度 1D-CNN 和注意力机制的汇率多步预测方法是一种有效且稳健的汇率预测模型, 与其他基准方法相比具有优越的性能.

本研究的贡献主要有以下几点: 第一, 设计了一种新的汇率多步预测框架, 该框架采用双重注意力机制结构, 通过增加权重计算大大提升了汇率多步预测的精度; 第二, 提出了一种新的汇率多步预测模型 DAMS-1DCNN. 具体而言, 采用多尺度 1D-CNN 进行特征提取, 降低非平稳特征的不利影响, 利用尺度注意力机制进一步提高特征的有效性, 采用时间注意力机制充分挖掘时间序列的相关性; 第三, 在三个汇率数据集上验证了本研究所提模型 DAMS-1DCNN 的性能, 实验结果表明本研究所提模型优于其他基准方法.

2 汇率预测文献综述

汇率是反映微观经济和宏观经济状况的重要指标之一, 汇率波动影响资产价格, 进而影响国际贸易、资产组合和风险管理^[8]. 因此, 汇率预测一直是研究者关注的焦点. 常见的汇率预测方法分为基于传统机器学习的方法和基于深度学习的方法.

2.1 基于传统机器学习的汇率预测方法

在早期的研究中, 许多研究人员使用统计方法预测汇率, 并开发了一些成熟的统计模型. 例如, 朱平芳等^[9] 将非参数可加模型与 RW 等方法进行比较, 实验结果表明非参数可加模型在多种汇率对上预测效果更好. Rout 等^[10] 使用混合 ARMA 模型在三种不同汇率数据集上预测了未来 15 个月的汇率值, 并将其与 ARMA 模型进行了比较. 实验结果表明, 使用混合模型的预测结果是最佳的. 郭琨和汪寿阳^[11] 使用 ARMA 模型和多变量的 CAR 模型, 对人民币兑美元的汇率对进行分析, 发现简单的组合模型预测精度更高. Liu^[12] 分别运用 ARIMA 模型和 GARCH 模型对美元指数进行了预测. 实验结果表明, ARIMA 模型更适用于短期预测, 而 GARCH 模型侧重于总体趋势预测. 但由于这类方法存在一定前提条件 (如数据平稳性、线性等), 在处理汇率这类非平稳数据时会呈现出较多不足.

近年来, 由于机器学习在很多领域都取得了巨大的成功, 被逐渐引入汇率预测研究中以提高预测精度. 目前典型的传统机器学习方法有 LR、SVR 和 ANN 等. 例如, Zhou 等^[13] 通过将 LR 模型级联到梯度增强决策树模型上构建一个新框架, 实验结果表明, 与其他模型相比所提出的框架有了显著的改进. Fu 等^[14] 使用 SVR 预测了四种典型的人民币汇率, 结果表明, 该模型在水平预测精度、方向预测精度和统计精度方面都优于其他基准模型. Evans 等^[15] 提出了一种基于 ANN 的每日汇率预测模型, 在英镑兑美元、欧元兑美元和美元兑人民币三个数据集上的检验结果表明, 该模型具有较高的精度并且能有效地支持投资者的相关决策. Kristjanpoller 等^[16] 设计了一种混合 ANN-GARCH 模型用于预测比特币的价格波动, 实验证明了 ANN 在检验非线性数据时的有效性. 然而, ANN 是一种不稳定的传统机器学习方法, 很容易陷入局部极小值^[2]. 不同于这些单一模型, 集成方法通过结合基础学习器的优势来获得更加稳定和准确的结果. 常见的集成方法有随机子空间 (random subspace, RS)、Adaboost 和 XGBoost 等. 例如, Wang 等^[17] 提出了一种基于浅层特征和深层特征互补的集成学习方法——自适应性稀疏随机子空间 (ALS-RS) 用于预测汇率, 在四个真实汇率数据集上的实验验证了所提方法的有效性. Bui 等^[18] 比较了单一模型和集成学习方法 Adaboost 在汇率预测中的性能, 结果证明 Adaboost 的性能优于单一模型. Jabeu 等^[19] 利用 XGBoost 等六种机器学习模型预测黄金价格走势, 实验结果表明 XGBoost 优

于其他先进的机器学习模型. 研究证明基于传统机器学习的时间序列预测方法相较于传统统计方法能够更好地处理非线性数据. 因为基于传统机器学习的时间序列预测方法不需要像传统统计方法在汇率数据与各个特征值之间建立复杂的关系式, 而是直接基于汇率数据进行自主学习. 然而, 基于传统机器学习的时间序列预测方法也存在一定问题, 如容易出现过拟合或局部最优解, 预测时具有一定滞后性等, 导致预测精度不够高.

2.2 基于深度学习的汇率预测方法

深度学习模型基于结构更复杂、层次更深的神经网络, 能够更加准确地学习到输入与输出数据之间的强非线性关系. 近年来, 越来越多的学者开始关注深度学习方法, 并将其应用于汇率预测领域. RNN 是用于时间序列预测最常见的模型之一, 已被广泛应用于汇率预测领域. 例如, Kiani 等^[20] 使用三种不同的 RNN 结构预测汇率. 在三个不同汇率对数据集上的检验结果表明, RNN 通常比其他模型表现更好. 尽管有很多研究证明了 RNN 的有效性, 但 RNN 存在梯度消失的问题, 并且只适用于短时间预测. 为了克服这一问题, RNN 的变体 LSTM 被开发出来并已广泛应用于汇率预测. LSTM 是通过添加一些多阈值门来解决存储和遗忘问题^[21]. 例如, Sun 等^[22] 构建了一个结合 LSTM 和 Bagging 集成学习策略的模型来预测汇率, 并发现所提出的模型显著优于其他基准方法. Zhang^[23] 设计了一个结合经验模式分解和 LSTM 的混合模型. 在美元兑人民币、欧元兑人民币和美元兑欧元三个数据集上的检验结果表明, 该模型具有较好的预测能力. GRU 的性能类似于 LSTM, 但 GRU 的参数更少, 收敛速度更快. 例如, Sako 等^[24] 将 GRU 应用于金融时间序列预测, 在八种股票市场指数和六种货币汇率数据集上的实证结果表明, 与 RNN 和 LSTM 相比, GRU 表现更好. 李章晓等^[25] 使用 GRU 预测汇率的期望收益率, 结合多目标进化算法优化投资组合, 在四组汇率数据集上的实验证明, 该方法在外汇交易市场中盈利的可能性. CNN 具有突出的特征提取能力, 被应用于许多领域. 例如, Alonso-Monsalve 等^[26] 比较了四种不同的网络结构 (CNN、混合 CNN-LSTM 网络、多层感知机和径向基函数神经网络) 在加密货币预测中的性能, 实验结果表明 CNN 能够在比特币、以太坊和莱特币加密货币中提供较好的结果. Galeshchuk 等^[27] 用 CNN 预测三对不同的汇率对, 实验结果表明, CNN 在预测汇率变化方向方面可以实现更高的分类精度. 然而, 传统 CNN 只能提取单一尺度的特征, 无法充分获取有效信息. 为了解决该问题, 有研究者使用多尺度 1D-CNN 来提取更多有效特征. 例如, Deng 等^[28] 提出了具有时间认知的多尺度 CNN 模型用于短期负荷的多步预测, 实验结果表明该方法具有很大的实际应用潜力.

上述深度学习方法虽然能够捕捉输入时间序列的时间变化, 但忽视了不同时间变量之间的相关性. 由此, 有研究者在时间序列预测中引入了注意力机制, 以提升预测效果. 例如, Li 等^[29] 构建了带有注意力机制的复合 GRU 模型来预测服装销售量, 实验结果证明, 该模型具有很大的发展潜力, 能够很好的帮助企业在智能制造领域提升竞争力. Yang 等^[30] 设计了一种用于时间序列预测的基于注意力机制的 Bi-GRU 网络, 通过在医学上的应用证实了该模型的有效性. 通过对汇率预测方面的文献梳理可知, 目前已开发出很多方法用于汇率预测并取得了一定成就. 然而, 现有的大多数深度学习汇率预测方法都是用于单步预测任务, 所获得的结果往往无法为决策者提供足够的决策信息. 此外, 由于汇率数据具有非平稳的特征, 直接利用传统深度学习方法进行预测无法充分挖掘汇率序列的特征及规律. 多尺度 1D-CNN 和注意力机制已在其他领域获得应用, 但鲜有研究将其应用于汇率预测领域, 这引发了本研究对于多尺度 1D-CNN 和注意力机制用于提高汇率预测精度的思考.

3 基于多尺度 1D-CNN 和双重注意力机制的方法构建

汇率是影响经济发展的重要影响因素之一, 准确预测汇率对于汇率预测使用者至关重要. 近年来随着深度学习技术的不断发展和完善, 越来越多学者开始关注基于深度学习的汇率预测研究. 然而, 目前大多数深度学习汇率预测研究只关注于单步预测, 实际上, 多步汇率预测更具有实际应用价值. 此外, 汇率数据具有非平稳特征, 使得特征提取过程更加困难, 汇率预测精度还有待提升. 为此, 本研究在编码器-解码器结构的基础上构建了一个新型汇率多步预测模型 DAMS-1DCNN, 利用该模型对三对汇率对的收盘价进行多步预测. 在编码器阶段, 利用多尺度 1D-CNN 对时间序列进行不同尺度的特征提取, 并

使用尺度注意力机制融合多尺度目标特征,生成更具代表性的特征;在解码器阶段,利用时间注意力机制赋予不同时间步相应权重,最后,引入 Bi-GRU 进一步挖掘时间序列过去和未来的动态时序特征,以提高汇率预测精度. DAMS-1DCNN 的具体结构如图 1 所示.

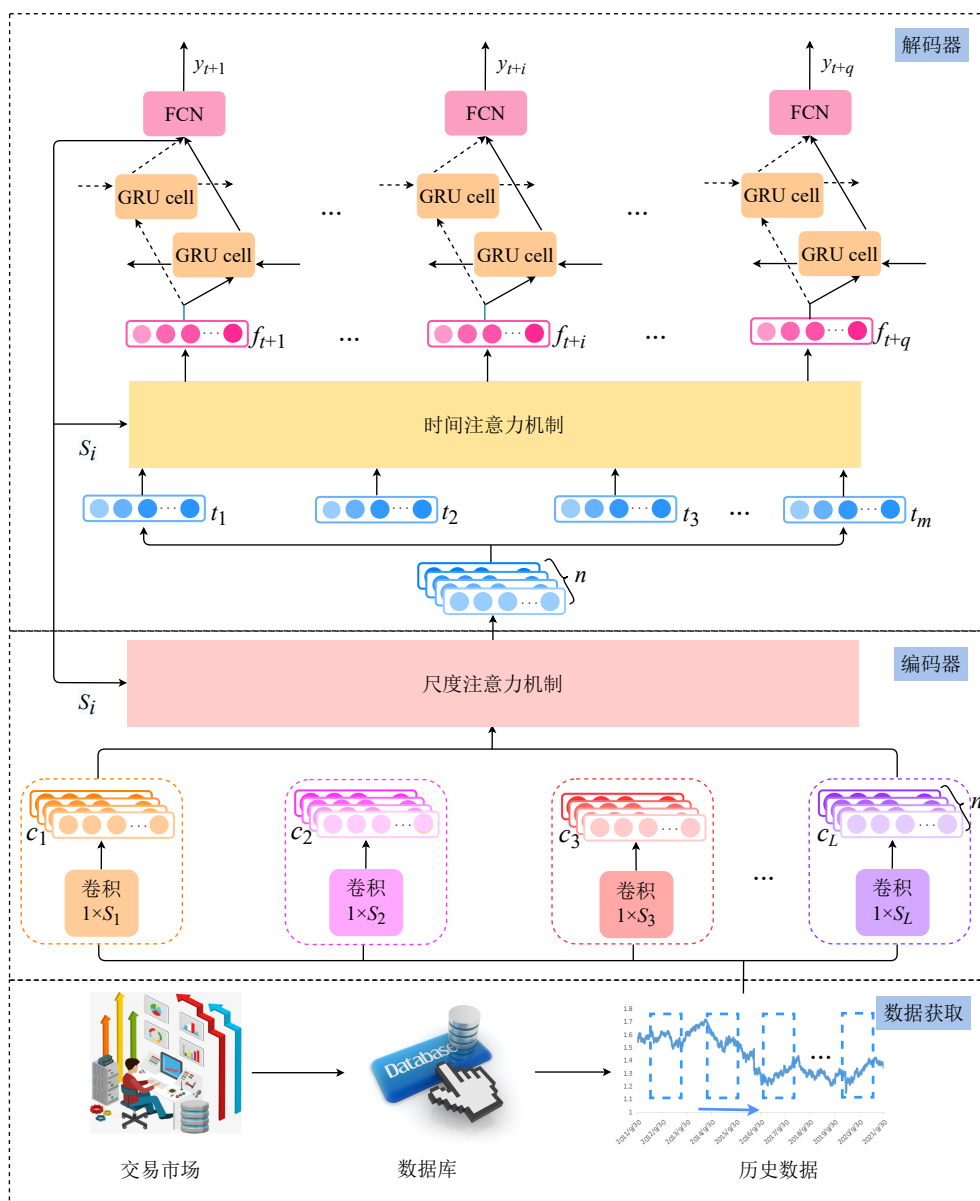


图 1 DAMS-1DCNN 整体框架

3.1 数据获取

本节介绍数据获取的过程. 相关机构根据外汇市场货币价格的波动进行记录更新, 如中央银行、官方的金融数据库以及金融机构等. 本研究所需的数据是欧元兑美元、英镑兑美元和美元兑人民币三种货币对的历史数据, 它显示了汇率波动的趋势、周期、季节和不规则性^[17]. 本研究数据来源英财网数据库.

3.2 基于多尺度 1D-CNN 的编码架构

汇率的多步预测任务是一个典型的序列到序列的问题, 由 Sutskever^[31] 提出的编码器-解码器框架被广泛应用于序列到序列的相关任务中. 例如, 曹阳等^[32] 使用 LSTM 作为编码器-解码器网络并引入注意力机制来预测日交通流. 在真实交通流数据集上的实验证明, 该方法相较于其他基准方法具有优越

性. Niu 等^[33] 在编码器-解码器的基础上设计了基于注意力机制的 GRU 模型来进行风功率的多步预测. 通过对三个不同案例研究, 证明了该模型在风功率预测中的有效性. 编码器-解码器由两部分组成: 编码器和解码器. 编码器将输入序列转换为隐藏状态序列, 然后将隐藏状态序列转换为固定长度的矢量. 最后, 解码器根据先前生成的固定矢量来预测目标输出序列. 将时间序列 $(x_1, x_2, \dots, x_t)$ 作为编码器的输入, $(y_{t+1}, y_{t+2}, \dots, y_{t+q})$ 是解码器最终的输出. 本研究使用多尺度 1D-CNN 作为编码器的基本单元, 因为汇率数据具有非平稳的特征, 传统的 CNN 只能提取单一尺度的特征, 无法充分获取有效信息. 因此, 本研究采用多尺度 1D-CNN 作为编码器, 通过多尺度的卷积核来学习汇率数据中的不同特性, 充分挖掘汇率序列的特征, 有效增强网络的特征表达能力, 进而降低汇率数据非平稳特征的不利影响.

编码器具体的操作过程: 将汇率的时间序列输入到多尺度 1D-CNN 模型中, 使用不同尺度的卷积核对待输入的汇率数据进行不同尺度的卷积操作, 提取不同精细度的特征. $S_1, S_2, \dots, S_L$ 分别代表不同尺度的卷积核, L 代表卷积核的尺度大小, 每个尺度卷积核有多个大小相同但权重不同的卷积核. 卷积层的具体运算过程如下:

$$c_l = \varphi(k_l \otimes x_l + b_l). \quad (1)$$

其中: k_l 代表长度为 l 的卷积核, x_l 表示的是输入的变量, b_l 是偏置向量, $\otimes$ 是卷积运算的符号, φ 表示的是 S 型激活函数 (sigmoid). 通过对整个输入的汇率时间序列进行卷积操作, 最终得到输出 c_l . 由于卷积操作后得到的特征长度不同, 因此需要对卷积层的所有输出进行相应尺度的池化操作, 使得最终的输出特征长度相同.

3.3 基于尺度注意力机制的多尺度特征融合

考虑到不同尺度的 CNN 所提取的特征对于最终汇率预测的重要性不同, 直接对多尺度特征进行融合可能会削弱相对重要尺度特征的作用, 本研究设计了尺度注意力机制来差异化融合多尺度 1D-CNN 的深度表达特征, 通过加入权重计算来加强或抑制不同尺度的特征信息, 以获得更具代表性的深度特征. 尺度注意力机制的架构图如图 2 所示.

将通过多尺度 1D-CNN 卷积操作后的得到的多尺度特征输入到尺度注意力机制中, 尺度注意力机制通过学习输入的不同尺度特征和最终预测结果的相关性, 赋予不同尺度特征相应的权重, 自适应的调整多尺度特征, 使得最终的综合特征更具有代表性, 从而提升模型的预测精度. 尺度注意力机制的具体运算过程如下:

$$e_l^i = (W_l^K K)^T (W_i^Q Q), \quad (2)$$

$$\alpha_l^i = \frac{\exp(e_l^i)}{\sum_{l=1}^L \exp(e_l^i)}, \quad (3)$$

$$z_m = \sum_{i=1}^t \alpha_l^i V, \quad (4)$$

其中: Q 和 K 表示的是计算尺度注意力机制权重的特征向量, V 表示的是输入的特征向量. 具体来看, K 和 V 是多尺度 1D-CNN 的最终输出 c_l , l 是卷积核的大小; Q 是解码器的输出 s_i ; e_l^i 表示 Q 与 K 的相似性, 即多尺度 1D-CNN 输出的多尺度特征与解码器隐藏层输出特征的相关性, 值越大说明该尺度的特征对于最终的预测值越重要; W_i^Q 和 W_l^K 分别为 s_i 和 c_l 的权重向量. 为了使得 e_l^i 近似服从标准正态分布, 采用激活函数 Softmax 将其归一化处理, 得到最终的权重 α_l^i . 最后进行加权求和处理, 获得综合特征 z_m .

3.4 基于时间注意力机制的时序特征融合

随着输入汇率时间序列长度的增加, 序列中所隐藏的有效信息也越多. 传统汇率预测方法将每个时间步的时间特征都同等对待, 但是事实上每个时间步特征对汇率预测准确性的贡献度是存在差异的. 同时, 尽管编码器-解码器有助于解决多步预测的误差累计问题, 但在处理长序列的输入特征时, 其学习能

力可能受到限制,从而导致模型预测精度下降.为了充分挖掘学习时间序列的相关性,本研究引入了时间注意力机制来识别相对重要的输入变量,避免信息的冗余,进一步提高模型预测精度.

根据变量对最终预测值的重要性赋予变量相应的权重,对目标序列中不同时间步间的动态时间相关性建模^[34],从而提高模型的预测精度.由于卷积操作后的特征内部是存在时序特征的,所以将综合特征 z_m 中同一时间值组成一个新的特征向量 t_j .然后将具有时间序列关系的特征向量输入到注意力机制中,依据不同时间步对于最终预测值的重要性赋予其相应权重.时间注意力机制的运算过程表示如下:

$$e_j^t = \tanh(W_1 s_{t-1} + U_1 t_j + b_1), \quad (5)$$

其中, t_j 表示经过尺度注意力机制融合后的综合特征在时间维度上组成的向量, s_{t-1} 表示的是解码器的输出, e_j^t 表示第 j 个时间步的特征 t_j 与 s_{t-1} 的相似性,值越大说明该变量对于最终的预测值越重要; W_1 、 U_1 和 b_1 为可学习的参数.

$$\beta_j^t = \frac{\exp(e_j^t)}{\sum_{j=1}^m \exp(e_j^t)}, \quad (6)$$

$$f_t = \sum_{j=1}^m \beta_j^t t_j. \quad (7)$$

为了使得 e_j^t 近似服从标准正态分布,采用激活函数 Softmax 将其归一化处理.最后进行加权求和处理,获得时间注意力机制的最终输出 f_t .




图2 尺度注意力机制架构




图3 时间注意力机制架构

3.5 基于 BiGRU 的解码架构

汇率数据之间是相互关联和相互影响的,存在很强的相关时序特征. GRU 作为一种有效的时序特性深度学习网络,可以很好地提取和储存相关的时序特征. GRU 是 RNN 的一种变体,是 LSTM 的简化版本. GRU 相较于 RNN 解决了梯度消失的问题;相比于 LSTM 减少了参数和加快了训练的速度.一般来说,传统的 GRU 只能从单一方向提取信息,但是汇率不仅受过去的信息的影响,而且还依赖于未来的趋势变化.为了克服这一局限性,本研究采用 Bi-GRU 作为解码器. Bi-GRU 的双向循环结构可以同时处理两个方向的数据,从而提高模型的准确性和灵活性. Bi-GRU 的具体运算过程如下:

$$\tilde{z}_t = \sigma(W_z \cdot [h_{t-1}, f_t] + b_z), \quad (8)$$

$$\tilde{r}_t = \sigma(W_r \cdot [h_{t-1}, f_t] + b_r), \quad (9)$$

$$\tilde{s}_t = \tanh(W_s \cdot [r_t \times h_{t-1}, f_t] + b_s), \quad (10)$$

$$\tilde{h}_t = (1 - z_t) \times \tilde{h}_{t-1} + z_t \times \tilde{s}_t, \quad (11)$$

$$h_t = [\vec{h}_t, \overleftarrow{h}_t], \quad (12)$$

其中, z_t 和 r_t 分别是更新门和重置门, 更新门决定了历史信息保存到当前时间步的量, 重置门则决定了输入的新信息如何与历史信息结合. σ 是激活函数 sigmoid, W_z 、 W_r 和 W_s 为相应门的权重参数, b_z 、 b_r 和 b_s 为可学习的偏置项参数. f_t 是经过时间注意力机制处理后的输出, $\tilde{h}_t$ 表示 $\vec{h}_t$ 或 $\overleftarrow{h}_t$, $\vec{h}_t$ 为前向 GRU 的输出, $\overleftarrow{h}_t$ 为后向 GRU 的输出. 将 GRU 的前向与后向输出拼接, 即可得到 Bi-GRU 的最终输出 h_t . 最后连接一个全连接层, 再到输出层, 实现多步预测结果 (y_{t+1} 、 y_{t+2} 、 $\cdots$ 、 y_{t+q}). 具体的方法流程如图 4 所示.




图 4 DAMS-1DCNN 的算法流程

4 实验设计

为了验证所提方法在汇率预测中的有效性, 本节选择了三种不同汇率对的历史价格数据集进行实验分析. 具体来看, 本节首先详细描述了实验所需的数据, 其次介绍本实验所使用的两种评价指标, 最后介绍本研究的实验过程.

4.1 实验数据与评价指标

本研究选取的三种不同的汇率对分别是欧元兑美元、英镑兑美元和美元兑人民币. 此外, 对于每个汇率对, 选取的是从 2011 年 9 月 30 日至 2021 年 9 月 30 日的每日收盘价, 共 2610 个观察结果. 为了评估模型预测的准确性, 本研究使用平均绝对百分比误差 (MAPE) 和均方根误差 (RMSE) 作为评估指标, 定义如下:

平均绝对百分比误差 (MAPE):

$$\text{MAPE} = \frac{1}{T} \sum_{t=1}^T \left| \frac{y_t - \hat{y}_t}{y_t} \right|. \quad (13)$$

均方根误差 (RMSE):

$$\text{RMSE} = \sqrt{\frac{1}{T} \sum_{t=1}^T (y_t - \hat{y}_t)^2}, \quad (14)$$

其中, T 为样本的数量, y_t 和 $\hat{y}_t$ 分别表示汇率收盘价的真实值与预测值. MAPE 和 RMSE 数值越小说明模型具有更低的误差水平和更好的预测性能.

4.2 实验过程

为了验证所提方法的有效性, 本研究选择了几种基准方法进行比较, 分别是五个传统方法 (ARIMA、SVR、RS、RW 和 XGBoost) 和四个深度学习方法 (LSTM、GRU、SEQ2SEQ-MS1DCNN 和 SEQ2SEQ-BiGRU). 其中, ARIMA 是一种被广泛应用于时间序列的统计方法, 在实验结果中 ARIMA 采用的是最优窗口大小. SVR 是一种经典的机器学习回归算法, 被广泛应用于汇率预测中. RS 是一种常见的集成方法, 通过选择不同的特征子集来训练每个基础学习器. RW 是一种广泛应用于金融领域的模型, 具有较高的预测精度. XGBoost 是一种高效的集成方法, 结合若干个弱分类器以提升预测精度. LSTM 是一种很流行的深度学习方法, 并越来越多地用于汇率预测任务中. GRU 在 LSTM 的基础上减少了门结构并加快了训练速度. SEQ2SEQ 是一种端到端的算法结构框架, 由编码器和解码器组成. 由于本研究的编码器和解码器部分采用了不同的网络结构, 所以分别比较了两种 SEQ2SEQ 模型, 即编码器与解码器均采用多尺度 1D-CNN 和编码器与解码器均采用 Bi-GRU 的网络结构. 为了保证实验的公平性, 本实验将数据集划分为训练集 (0.8) 和测试集 (0.2), 2011 年 9 月 30 至 2019 年 10 月 1 日的每日历史数据 (共计 2088 个观察结果), 作为样本内数据集来训练预测模型, 2019 年 10 月 2 日至 2021 年 9 月 30 日的每日历史数据 (共计 522 个观察结果), 作为样本外数据集来检验模型的性能. 在训练集上对所有模型进行训练调参, 最后将训练好的模型在测试集上进行最终测试. 重复上述实验过程十次可得到不同的评估结果, 最终将十次结果的均值作为实验结果. 训练期间的网络超参数设置如下: 训练轮次 (epoch) 设为 200, 训练批量大小 (batch size) 设为 32, 滑动窗口的长度设为 21 天, dropout 比例设为 0.1. 实验中使用的 LSTM 和 GRU 的层数为两层, 隐藏层维度分别设为 64 和 32; 多尺度 1D-CNN 中依次使用了尺度为 3、5、7 的一维卷积核, 输出维度设为 6.

5 结果分析与讨论

5.1 实验结果

本研究使用所提方法和基准方法对未来 1、3、6 天的汇率值进行预测, 表 1~3 给出了在三个数据集上两个评估指标的实验结果. 粗体字表示各方法下的最优预测结果.

如表 1 所示, 对于 EUR/USD 而言, DAMS-1DCNN 在三个预测步数下的 MAPE 值分别为 0.3109%、0.5675%、0.7845%, 是所有方法中最小的, 表明了本研究方法在汇率多步预测中的优异性能. 同样地, DAMS-1DCNN 的 RMSE 值也是最小的, 进一步证明本研究方法的有效性. 如表 2 和表 3 所示, 对于 GBP/USD 和 USD/CNY 而言, DAMS-1DCNN 的 MAPE、RMSE 的值都是最小的. 可以看出, 本研究所提方法在三个不同数据集下的预测效果都优于其他基准方法, 证明了其在汇率多步预测中的有效性和鲁棒性.

具体来说, 本研究首先将统计方法与机器学习方法进行比较. 不同数据集上 SVR 的预测效果都比 ARIMA 好, 这说明机器学习比统计方法更适用于汇率预测. 不论是 MAPE 还是 RMSE 的值, 不同数据集上的 RS 和 XGBoost 都比 ARIMA 的值要低些, 这进一步说明机器学习相较于统计方法的优越性. 由于随机游走模型能够较好地捕捉汇率的短期波动, 预测效果优于一些传统机器学习方法, 但是本研究的模型效果仍远高于随机游走. 其次, 本研究将单一模型与集成方法进行比较. 三种数据集上的 RS 和 XGBoost 总体预测效果都比 SVR 更好, 这说明集成方法较单一模型在处理汇率数据集上更具有优势. 然后, 本研究将传统机器学习方法与深度学习方法进行比较. 深度学习方法对于数据的利用程度以及数据的特征提取能力均超过了传统机器学习方法. LSTM、GRU 和 SEQ2SEQ-MS1DCNN 等深度学习方法的 MAPE 和 RMSE 都明显低于传统机器学习, 说明深度学习比传统机器学习方法更适用于汇率预测. 最后, 本研究比较了不同的深度学习方法. SEQ2SEQ 模型要比 LSTM 和 GRU 的预测效果好, 说明 SEQ2SEQ 对于汇率多步预测更具有优势. DAMS-1DCNN 相较于 SEQ2SEQ 的预测精度有明显提

升, 因为本研究考虑到汇率数据的非平稳的特征以及不同特征的贡献差异, 增加了多尺度 1D-CNN 和注意力机制, 进而提高了模型的预测精度.

表 1 EUR/USD 数据集的各模型预测结果对比

方法	提前 1 天		提前 3 天		提前 6 天	
	MAPE(%)	RMSE(%)	MAPE(%)	RMSE(%)	MAPE(%)	RMSE(%)
ARIMA	0.5547	0.8525	0.7408	1.2340	1.0191	1.5685
SVR	0.4730	0.7343	0.6887	1.0566	0.8977	1.3557
RS	0.3775	0.5822	0.6198	0.9433	0.8157	1.2570
RW	0.3654	0.5678	0.6084	0.9402	0.8113	1.2435
XGBoost	0.3864	0.5931	0.6214	0.9511	0.8325	1.2703
LSTM	0.3951	0.6085	0.6164	0.9445	0.7990	1.2400
GRU	0.4076	0.6167	0.6311	0.9488	0.8010	1.2481
SEQ2SEQ-MS1DCNN	0.3836	0.5754	0.6062	0.9336	0.7951	1.2391
SEQ2SEQ-BiGRU	0.3461	0.5249	0.5877	0.8905	0.7915	1.2217
DAMS-1DCNN	0.3109	0.4669	0.5675	0.8621	0.7845	1.2082

表 2 GBP/USD 数据集的各模型预测结果对比

方法	提前 1 天		提前 3 天		提前 6 天	
	MAPE(%)	RMSE(%)	MAPE(%)	RMSE(%)	MAPE(%)	RMSE(%)
ARIMA	0.5634	0.9647	0.8920	1.5890	1.1619	2.1289
SVR	0.5480	0.9915	0.8381	1.5774	1.1198	2.1467
RS	0.5174	0.9215	0.8179	1.5319	1.1071	2.1441
RW	0.4638	0.7901	0.7956	1.4485	1.0738	2.1297
XGBoost	0.5019	0.8894	0.8102	1.5164	1.0897	2.1326
LSTM	0.4789	0.8522	0.8157	1.5237	1.0994	2.1301
GRU	0.5079	0.8910	0.8070	1.5007	1.0787	2.1124
SEQ2SEQ-MS1DCNN	0.4632	0.7891	0.7911	1.4319	1.0699	2.0732
SEQ2SEQ-BiGRU	0.4486	0.7708	0.7834	1.4296	1.0605	2.0836
DAMS-1DCNN	0.4206	0.7488	0.7748	1.4183	1.0474	2.0698

表 3 USD/CNY 数据集的各模型预测结果对比

方法	提前 1 天		提前 3 天		提前 6 天	
	MAPE(%)	RMSE(%)	MAPE(%)	RMSE(%)	MAPE(%)	RMSE(%)
ARIMA	0.3137	2.6391	0.3951	3.3985	0.4869	4.1358
SVR	0.2797	2.5814	0.3799	3.3915	0.4695	4.1253
RS	0.2750	2.5702	0.3766	3.3663	0.4830	4.2491
RW	0.2439	2.1638	0.3364	2.9547	0.4726	4.0813
XGBoost	0.2537	2.2701	0.3431	3.0789	0.4657	4.0659
LSTM	0.2511	2.2671	0.3429	3.0514	0.4687	4.0648
GRU	0.2563	2.2799	0.3436	3.1077	0.4613	4.0676
SEQ2SEQ-MS1DCNN	0.2584	2.2466	0.3373	2.9637	0.4669	4.0617
SEQ2SEQ-BiGRU	0.2337	2.1501	0.3248	2.9113	0.4443	3.9004
DAMS-1DCNN	0.1944	1.7866	0.3054	2.7267	0.4339	3.7739

5.2 分析与讨论

5.2.1 汇率预测值与真实值的比较

为更好地说明本研究方法的有效性, 对三种汇率对的真实值和预测值拟合效果进行分析, 结果如图 5~7 所示.




图 5 使用 DAMS-1DCNN 提前 1 天预测的实际结果与预测结果




图 6 使用 DAMS-1DCNN 提前 3 天预测的实际结果与预测结果

图 5~7 分别反映了使用 DAMS-1DCNN 在三个预测步数下预测三对汇率对的预测值和真实值的对比曲线. 由图 5 可知, 在提前 1 天的预测中, 三对汇率对的预测曲线与实际曲线非常接近, 这证明本研究方法在单步预测中具有很高的预测精度. 根据图 6 可知, 提前 3 天预测的拟合结果总体虽然没有提前一天的拟合效果好, 但是欧元兑美元的拟合结果和提前 1 天预测的拟合效果相差无几, 美元兑人民币的预测误差略微上升. 由图 7 所示, 在提前 6 天的预测中, 欧元兑美元和美元兑人民币均取得了不错的




图7 使用 DAMS-1DCNN 提前 6 天预测的实际结果与预测结果


拟合效果;英镑兑美元虽没有另外两对拟合效果好,但是汇率真实值和预测值曲线的波形非常接近.综上所述, DAMS-1DCNN 对于整体汇率变化趋势能产生较为准确的预测结果,证实了本研究方法对于汇率多步预测的有效性.

5.2.2 消融实验研究


为了验证所提方法 DAMS-1DCNN 中的每个模块的效用及其对于预测性能的影响程度,本研究进行了消融实验研究,构建了4种变体模型与本研究模型进行对比. DA-CNN: 将本研究模型的编码器阶段的多尺度1D-CNN和尺度注意力机制模块换成传统CNN; TAMS-1DCNN: 去除本研究模型的编码器阶段的尺度注意力机制; STMS-1DCNN: 去除本研究模型的解码器阶段的时间注意力机制; MS-1DCNN: 去除本研究模型的编码器阶段的尺度注意力机制和解码器阶段的时间注意力机制.三对汇率对的消融实验结果如图8~10所示.

由图8~10可知: DAMS-1DCNN 通过考虑汇率数据的非线性、非平稳的特征,具备了比 DA-CNN 更优的性能,证明了多尺度1D-CNN的应用相较于将汇率数据输入传统CNN的优势,验证了多尺度1D-CNN 优越的特征提取能力. DAMS-1DCNN 通过考虑不同尺度特征的重要性差异以及不同时间步对于最终预测的影响程度不同,具备了比 MS-1DCNN 更优的预测能力,具体来看, DAMS-1DCNN 在三个预测步数下的 MAPE 值分别较 MS-1DCNN 降低了 15.9957%、8.6593%和 13.1518%,验证了应用尺度注意力机制和时间注意力机制比直接将汇率数据输入多尺度1D-CNN 编码器,再将上下文向量输入 Bi-GRU 解码器的优势,证明了尺度注意力机制和时间注意力机制对于汇率多步预测的有效性. DAMS-1DCNN 通过考虑不同尺度特征对于汇率预测的重要性差异,增强了特征的有效性,具备了比 TAMS-1DCNN 更优的性能,具体来看, DAMS-1DCNN 在三个预测步数下的 MAPE 值分别较 TAMS-1DCNN 降低了 4.6026%、6.5997%和 2.4132%,验证了尺度注意力机制的应用相较于直接将不同尺度特征平均成为一个综合特征更有利于准确预测多步汇率值,证明了尺度注意力机制对于汇率多步预测的有效性. DAMS-1DCNN 通过考虑不同时间步对于最终预测的影响程度不同,自适应的为每个时间步值赋予相应权重,具备了比 STMS-1DCNN 更好的性能,具体来看, DAMS-1DCNN 在三个预测步数下的 MAPE 值分别较 STMS-1DCNN 降低了 1.3329%和 2.1045%和 0.8593%,验证了将时间注意力机制

生成的上下文向量输入 Bi-GRU 相较于直接将编码器的输出向量输入 Bi-GRU 的有效性, 证明了时间注意力机制对于汇率多步预测的有效性. 可以看出, 通过消融实验分析的结果, 有助于可视化每个模块的效用及其对于预测性能的影响程度, 从而为未来经济工作者选取或改进深度学习模型算法进行短期汇率预测提供决策支持.




(a) 不同方法的 MAPE 值




(b) 不同方法的 RMSE 值

图 8 EUR/USD 数据集在不同预测步数下的预测结果




(a) 不同方法的 MAPE 值




(b) 不同方法的 RMSE 值

图 9 GBP/USD 数据集在不同预测步数下的预测结果



(a) 不同方法的 MAPE 值



(b) 不同方法的 RMSE 值

图 10 USD/CNY 数据集在不同预测步数下的预测结果

5.2.3 参数敏感性分析

由于汇率受多种因素的影响, 数据的非平稳性增加了数据的复杂性, 因此如何选取合适的卷积核尺度以提取更重要的特征具有重要意义. 图 11 显示了所提方法在不同尺度数量下的性能趋势, 其中圆形线表示的是 MAPE, 方形线表示的是 RMSE.

若卷积核的尺度过大会导致网络训练参数增加, 网络的复杂度也会增加, 影响网络的训练效率; 反之, 卷积核的尺度过小会导致特征提取不充分, 影响汇率预测的准确性. 为了选择更合适的卷积核尺度数量, 本研究进行了相关实验, 将尺度数量分别设置为 1、2、3、4 和 5, 以评估不同尺度数量对于本研究模型性能的影响. 由于三种汇率对的模型构建方法完全相似, 故这里只对以欧元兑美元汇率对为代表进行分析研究. 如图 10 所示, DAMS-1DCNN 在提前 1 天的预测中, 尺度数量为 3 时误差最小; 在提前 3 天的预测中, 尺度数量为 2 时误差最小; 在提前 6 天的预测中, 尺度数量为 2 时误差最小. 无论预测步数是多少, 单尺度方法的误差均是最高. 随着尺度增加, 所构建的方法具有更高的预测精度, 但是当尺度数量增加到一定程度时, 特征的冗余使得方法性能有所下降. 因此, 可以得出结论, 适度的卷积核尺度数可以使模型学到更好的特征, 从而提高模型的预测精度.




图 11 不同尺度数量下 DAMS-1DCNN 的预测结果

6 结论

汇率多步预测能推动和促进汇率预测相关研究的进一步发展, 并可以为企业国际贸易中的外汇风险管理以及个人投资策略的调整提供参考. 例如, 通过短期汇率多步预测, 企业和个人可以采取相应的套期保值措施, 以减少因短期内汇率波动对现有外币资产或负债的影响, 从而降低短期风险. 现有研究

多是专注于单步汇率预测,然而在实际应用中,汇率多步预测往往更加重要。此外由于汇率数据具有非平稳的特点,传统的 CNN 只能提取单一尺度的特征,无法充分获取有效信息。因此,本研究提出了一种基于多尺度 1D-CNN 和注意力机制的汇率多步预测方法,在三对汇率数据集上的实验结果证明,该方法有效提高了汇率多步预测的准确度。本研究下一步的研究方向将从以下几点展开:第一,本研究只预测了 1 天、3 天和 6 天的短期汇率多步值,为了提供给汇率预测使用者更多决策支持,可以进一步拉长汇率预测的时间。第二,小时汇率、分钟汇率等高频汇率数据有利于提高汇率多步预测的精度,未来可以将本研究使用的日数据转化为更高频率的汇率数据。第三,本研究只使用了汇率的历史数据,属于单变量预测。然而,汇率波动受多种因素的影响,包括经济因素、政治因素和社会因素等,本研究在预测模型建模过程中,忽略了对这些因素的考虑,对于突发事件的解释能力不足。未来在预测模型建模过程中将考虑影响汇率变动的因素,如利率、通货膨胀、产出缺口等,并将新设计的方法与经济基本面模型进行比较。第四,本研究所提的深度学习模型相比于机器学习和传统经济模型在数据信息利用方面的优势呈现较为抽象,可解释性弱。未来将重点关注可解释的深度学习方法,以便更多经济工作者理解和使用。

参考文献

- [1] 孙少龙,魏云捷,汪寿阳. 基于分解-聚类-集成学习的汇率预测方法[J]. 系统工程理论与实践, 2022, 42(3): 664-677.
Sun S L, Wei Y J, Wang S Y. Exchange rates forecasting with decomposition-clustering-ensemble learning approach[J]. Systems Engineering — Theory & Practice, 2022, 42(3): 664-677.
- [2] Dash R. An improved shuffled frog leaping algorithm based evolutionary framework for currency exchange rate prediction[J]. Physica A: Statistical Mechanics and its Applications, 2017, 486: 782-796.
- [3] Drucker H, Burges C J C, Kaufman L, et al. Support vector regression machines[C]// 10th Annual Conference on Neural Information Processing Systems (NIPS), 1996: 155-161.
- [4] 张健,孙玉莹,张新雨,等. 基于时变模型平均方法的我国航空客运量预测[J]. 系统工程理论与实践, 2020, 40: 1509-1519.
Zhang J, Sun Y Y, Zhang X Y, et al. Time-varying forecast averaging for air passengers in China[J]. Systems Engineering — Theory & Practice, 2020, 40(6): 1509-1519.
- [5] 许杰,祝玉坤,邢春晓. 机器学习在金融资产定价中的应用研究综述[J]. 计算机科学, 2022, 49: 276-286.
Xu J, Zhu Y K, Xing C X. Application of machine learning in financial asset pricing: A review[J]. Computer Science, 2022, 49(6): 276-286.
- [6] 刘小勇,郑琨. 光纤缺陷实时检测与分类方法研究[J]. 西安交通大学学报, 2014, 48: 1-5.
Liu X Y, Zheng K. Research on optical fiber defect real-time detection and classification[J]. Journal of Xi'an Jiaotong University, 2014, 48: 1-5.
- [7] 高德欣,刘欣,杨清. 基于卷积神经网络与双向长短时融合的锂离子电池剩余使用寿命预测[J]. 信息与控制, 2022, 51(3): 318-329.
Gao D X, Liu X, Yang Q. Remaining useful life prediction of lithium-ion battery based on CNN and BiLSTM fusion[J]. Information and Control, 2022, 51(3): 318-329.
- [8] Yang H L, Lin H C. Applying the hybrid model of EMD, PSR, and ELM to exchange rates forecasting[J]. Computational Economics, 2015, 49: 99-116.
- [9] 朱平芳,董朝华,刘亚莉,等. 汇率预测的“米斯和罗格夫之谜”破解——来自非参数方法的回答[J]. 系统工程理论与实践, 2020, 40(6): 1495-1508.
Zhu P F, Dong C H, Liu Y L, et al. “The Meese and Rogoff puzzle” in exchange rate forecasting — Answers from nonparametric methods[J]. Systems Engineering — Theory & Practice, 2020, 40(6): 1495-1508.
- [10] Rout M, Majhi B, Majhi R, et al. Forecasting of currency exchange rates using an adaptive ARMA model with differential evolution based training[J]. Journal of King Saud University — Computer and Information Sciences, 2014, 26: 7-18.
- [11] 郭琨,汪寿阳. 人民币汇率预测的两种模型[J]. 系统工程理论与实践, 2008, 28(5): 64-69.
Guo K, Wang S Y. Two models for predicting the exchange rate of the RMB[J]. Systems Engineering — Theory & Practice, 2008, 28(5): 64-69.
- [12] Liu Z, Lv Y. A Study of the USDX Predication Based on ARIMA and GARCH Models[C]// 2011 Fourth International Conference on Business Intelligence and Financial Engineering, 2011: 82-85.
- [13] Zhou F, Zhang Q, Sornette D, et al. Cascading logistic regression onto gradient boosted decision trees for

- forecasting and trading stock indices[J]. *Applied Soft Computing*, 2019, 84. doi: 10.1016/j.asoc.2019.105747.
- [14] Fu S, Li Y, Sun S, et al. Evolutionary support vector machine for RMB exchange rate forecasting[J]. *Physica A: Statistical Mechanics and its Applications*, 2019, 521: 692–704.
- [15] Evans C, Pappas K, Xhafa F. Utilizing artificial neural networks and genetic algorithms to build an algo-trading model for intra-day foreign exchange speculation[J]. *Mathematical and Computer Modelling*, 2013, 58: 1249–1266.
- [16] Kristjanpoller W, Minutolo M C. A hybrid volatility forecasting framework integrating GARCH, artificial neural network, technical analysis and principal components analysis[J]. *Expert Systems with Applications*, 2018, 109: 1–11.
- [17] Wang G, Tao T, Ma J L, et al. An improved ensemble learning method for exchange rate forecasting based on complementary effect of shallow and deep features[J]. *Expert Systems with Applications*, 2021, 184. doi: 10.1016/j.eswa.2021.115569.
- [18] Bui L T, Vu V T, Dinh T T H. A novel evolutionary multi-objective ensemble learning approach for forecasting currency exchange rates[J]. *Data & Knowledge Engineering*, 2018, 114: 40–66.
- [19] Jabeur S B, Mefteh-Wali S, Viviani J L. Forecasting gold price with the XGBoost algorithm and SHAP interaction values[J]. *Annals of Operations Research*, 2021. <https://doi.org/10.1007/s10479-021-04187-w>.
- [20] Kiani K M, Kastens T L. Testing forecast accuracy of foreign exchange rates: Predictions from feed forward and various recurrent neural network architectures[J]. *Computational Economics*, 2008, 32: 383–406.
- [21] Li Y, Zhu Z, Kong D, et al. EA-LSTM: Evolutionary attention-based LSTM for time series prediction[J]. *Knowledge-Based Systems*, 2019, 181. doi: 10.48550/arXiv.1811.03760.
- [22] Sun S, Wang S, Wei Y. A new ensemble deep learning approach for exchange rates forecasting and trading[J]. *Advanced Engineering Informatics*, 2020, 46: 101160.
- [23] Zhang B. Foreign exchange rates forecasting with an EMD-LSTM neural networks model[C]// *Journal of Physics: Conference Series*. IOP Publishing, 2018, 1053(1): 012005.
- [24] Sako K, Mpinda B N, Rodrigues P C. Neural networks for financial time series forecasting[J]. *Entropy*, 2022, 24(5): 657. <https://doi.org/10.3390/e24050657>.
- [25] 李章晓, 宋微, 田野. 基于深度学习和进化计算的外汇预测与投资组合优化 [J]. *郑州大学学报 (工学版)*, 2019, 40: 92–96.
- Li Z X, Song W, Tian Y. Exchange rate forecasting and portfolio optimization based on deep learning and evolutionary computation[J]. *Journal of Zhengzhou University (Engineering Science)*, 2019, 40(1): 92–96.
- [26] Alonso-Monsalve S, Suárez-Cetrulo A L, Cervantes A, et al. Convolution on neural networks for high-frequency trend prediction of cryptocurrency exchange rates using technical indicators[J]. *Expert Systems with Applications*, 2020, 149. doi: 10.1016/j.eswa.2020.113250.
- [27] Galeshchuk S, Mukherjee S. Deep networks for predicting direction of change in foreign exchange rates[J]. *Intelligent Systems in Accounting, Finance and Management*, 2017, 24: 100–110.
- [28] Deng Z, Wang B, Xu Y, et al. Multi-scale convolutional neural network with time-cognition for multi-step short-term load forecasting[J]. *IEEE Access*, 2019, 7: 88058–88071.
- [29] Li Y, Yang Y, Zhu K, et al. Clothing sale forecasting by a composite gru-prophet model with an attention mechanism[J]. *IEEE Transactions on Industrial Informatics*, 2021, 17: 8335–8344.
- [30] Yang Z, Tian Y, Zhou T, et al. Time-series deep survival prediction for hemodialysis patients using an attention-based Bi-GRU network[J]. *Comput Methods Programs Biomed*, 2021, 212: 106458.
- [31] Sutskever I, Vinyals O, Le Q V. Sequence to sequence learning with neural networks[C]// *28th Conference on Neural Information Processing Systems (NIPS)*, 2014.
- [32] 曹阳, 茅一波, 施佳. 日交通流预测的编码器-解码器深度学习模型研究 [J]. *计算机工程与应用*, 2022, 58: 284–290.
- Cao Y, Mao Y B, Shi Q. Research on encoder-decoder deep learning model for daily traffic flow prediction[J]. *Computer Engineering and Applications*, 2022, 58(22): 284–290.
- [33] Niu Z, Yu Z, Tang W, et al. Wind power forecasting using attention-based gated recurrent unit network[J]. *Energy*, 2020, 196. doi: 10.1016/j.energy.2020.117081.
- [34] 张杰, 甄柳琳, 翟东升. 基于多级注意力机制的大豆期货预测研究 [J]. *系统工程*, 2023, 41(2): 148–158.
- Zhang J, Zhen L L, Zhai D S. Forecasting for soybean features based on multistage attention mechanism[J]. *Systems Engineering*, 2023, 41(2): 148–158.